

BEYKOZ

ÜNİVERSİTESİ

LİNEER CEBİR DERSİ DÖNEM SONU FİNAL PROJESİ

**VİDEO SEGMENTASYONU VE LİNEER CEBİR TABANLI TRAFİK YOĞUNLUĞU
ANALİZİ İLE AKILLI SİNYALİZASYON KARAR DESTEK SİSTEMİ TASARIMI**

Hazırlayan: Mert GÖZÜBÜYÜK

Öğrenci No: 2504040157

Video Segmentasyonu ve Lineer Cebir Tabanlı Trafik Yoğunluğu Analizi ile Akıllı Sinyalizasyon Karar Destek Sistemi Tasarımı

Özet

Günümüz metropollerinde kontrolsüz nüfus artışı ve araç sahipliği oranlarındaki yükseliş, kentsel ulaşım ağlarında kronik trafik sıkışıklıklarına yol açmaktadır. Geleneksel sabit süreli sinyalizasyon sistemleri, dinamik trafik yüklerine uyum sağlayamamakta ve zaman kaybı ile karbon emisyonunun artmasına neden olmaktadır. Bu çalışmada, video segmentasyonu ve karar destek sistemi (KDS) temelli akıllı bir kavşak yönetim modeli bilimsel bir çerçevede ele alınmıştır. Sabit açılı trafik kameralarından elde edilen video akışları, lineer cebirsel matris dönüşümleri ve ardışık kare farkı (Background Subtraction) yöntemi kullanılarak piksel düzeyinde segmentasyona tabi tutulmuştur. Elde edilen ikili (binary) matrisler üzerinden norm hesaplamaları yapılarak anlık araç yoğunluğu sayısal verilere dönüştürülmüştür. Geliştirilen Karar Destek Sistemi, bu yoğunluk verilerini girdi olarak alarak yeşil ışık sürelerini dinamik ve optimize bir şekilde optimize etmektedir. Sistem mimarisinin performansı, doğruluk oranı ve sinyalizasyon gecikme süreleri üzerinden değerlendirilmiştir. Sonuçlar, önerilen yöntemin trafik yoğunluğunu analiz etmede ve karar destek mekanizması oluşturmada etkili olduğunu göstermektedir

Anahtar Kelimeler: Video Segmentasyonu, Karar Destek Sistemleri, Lineer Cebir, Matris Dönüşümleri, Akıllı Ulaşım Sistemleri. (5 adet)

1. Giriş

Akıllı Ulaşım Sistemleri (AUS), modern şehir planlamasının ve yazılım mühendisliğinin en kritik araştırma alanlarından birini oluşturmaktadır. Kent içi hareketliliğin optimize edilmesi, yalnızca sosyo-ekonomik kayıpların azaltılması açısından değil, aynı zamanda çevre kirliliğinin önlenmesi bağlamında da büyük önem arz etmektedir. Geleneksel trafik yönetim altyapıları, belirli saat dilimlerine göre optimize edilmiş statik süre tablolarına dayanmaktadır (Papageorgiou ve diğerleri, 2003). Ancak anlık kazalar, hava muhalefeti veya beklenmedik yoğunluk dalgalanmaları karşısında bu sistemler yetersiz kalmakta ve kavşaklarda tıkanmalara yol açmaktadır. Bilgisayarlı görüş (computer vision) ve örüntü tanıma

teknolojilerindeki gelişmeler, trafik durumunun gerçek zamanlı olarak izlenmesine ve anlamlandırılmasına olanak tanımaktadır (**Zhang ve diğerleri, 2021**). Dijital video işleme süreçlerinin temelinde lineer cebir ve matris teorisi yer almaktadır (**Gonzalez ve Woods, 2018; Bansal ve diğerleri, 2022**). Bir video akışını oluşturan her bir kare, özünde belirli boyutlarda sayısal iki boyutlu veya üç boyutlu birer matristir. Piksel yoğunluklarının matris elemanları olarak temsil edilmesi, görüntü üzerindeki değişimlerin matematiksel operatörler yardımıyla analiz edilmesini sağlar. Hareketli nesnelerin tespiti ve takibi, ardışık matrisler arasındaki doğrusal ilişkilerin incelenmesi ve norm hesaplamaları ile gerçekleştirilmektedir. Bu doğrultuda, video segmentasyonu teknikleri kullanılarak araçların arka plandan (yol, binalar, ağaçlar vb.) ayrıştırılması, trafik yoğunluğunun nesnel ve sayısal bir şekilde ölçülmesinin ilk adımını oluşturur.

Yalnızca verinin toplanması trafik probleminin çözümü için yeterli değildir; toplanan bu teknik verilerin anlamlı birer mühendislik aksiyonuna dönüştürülmesi gerekmektedir. Bu noktada devreye giren Karar Destek Sistemleri (KDS), segmentasyon aşamasından gelen anlık araç yoğunluk matrislerini işleyerek kavşaktaki sinyalizasyon sürelerini o anki ihtiyaca göre yeniden şekillendirir. Bu çalışmanın temel amacı; sabit açılı bir trafik kamerasından alınan görüntüleri lineer cebirsel yöntemlerle segmente etmek, kavşaktaki doluluk oranını matematiksel olarak modellemek ve bu verilere dayanarak optimize edilmiş ışık süreleri üreten dinamik bir karar destek mekanizması tasarlamaktır.

Çalışmanın geri kalan kısmı şu şekilde organize edilmiştir: İkinci bölümde konuyla ilgili literatürdeki mevcut çalışmalar incelenmiş; üçüncü bölümde veri ön işleme, video segmentasyonu ve KDS tasarımı ait matematiksel ve sistemsel metodoloji detaylandırılmıştır. Dördüncü bölümde deneysel bulgular ve görsel çıktılar sunulmuş; beşinci bölümde elde edilen sonuçlar tartışılmış ve son bölümde ise gelecekteki çalışmalara yönelik önerilerle makale sonlandırılmıştır.

2. Literatür Taraması

Trafik yoğunluğu analizi ve araç tespiti, bilgisayarlı görü literatüründe geniş bir yer tutmaktadır. Geleneksel yöntemler genellikle manyetik döngü dedektörleri, mikrodalga radarlar ve ultrasonik sensörler gibi donanım tabanlı çözümlere dayanmaktaydı. Ancak bu sistemlerin kurulum maliyetlerinin yüksek olması ve bakım zorlukları, araştırmacıları daha düşük maliyetli ve esnek olan video tabanlı analiz sistemlerine yöneltmiştir.

Görüntü işleme tabanlı trafik analizinin temelini, her bir video karesinin birer matris olarak temsil edilmesi oluşturur. Literatürde, hareketli nesnelerin tespiti için en yaygın kullanılan yöntemlerden biri Arka Plan Çıkarma (Background Subtraction) tekniğidir. Bu yöntemde, durağan bir arka plan modeli oluşturulmakta ve güncel kare ile arka plan modeli arasındaki fark matrisi ($D = |A_t - B|$) hesaplanmaktadır (**Piccardi, 2004**). Kim ve diğerleri (2019) tarafından yapılan bir çalışmada, matris çıkarma işleminin ardından uygulanan eşikleme yönteminin, düşük ışıklı ortamlarda bile araç segmentasyonunda yüksek başarı sağladığı gösterilmiştir.

Lineer cebirsel dönüşümlerin görüntü segmentasyonu üzerindeki etkisi, özellikle boyut indirgeme ve gürültü temizleme aşamalarında öne çıkmaktadır. Tekil Değer Ayrışımı (SVD) ve Temel Bileşen Analizi (PCA), video verisindeki durağan pikselleri (düşük ranklı bileşenler) hareketli piksellerden (seyrek bileşenler) ayırmak için yaygın olarak kullanılmaktadır. Candes ve diğerleri (2011) tarafından önerilen "Robust PCA" yöntemi, video akışlarını düşük ranklı bir arka plan matrisi (L) ve seyrek bir hareket matrisi (S) şeklinde ayırıştırarak ($A = L + S$), karmaşık hava koşullarında bile araçların yüksek doğrulukla segmente edilmesini sağlamıştır.

Segmentasyon aşamasından elde edilen verilerin bir Karar Destek Sistemi'ne (KDS) dönüştürülmesi süreci, trafik mühendisliğinin karar mekanizması bileşenini oluşturur. Dinamik sinyalizasyon yönetimi üzerine yapılan araştırmalar, bulanık mantık ve sinir ağları temelli karar algoritmalarının, sabit süreli sistemlere oranla bekleme sürelerini %25 ile %40 arasında azalttığını ortaya koymaktadır (**Tanasiev ve diğerleri, 2020**). Özellikle yoğunluk matrislerinin norm değerleri üzerinden yapılan hesaplamalar, kavşaklardaki doluluk oranının sayısal bir göstergesi olarak kabul edilmekte ve sinyalizasyon sürelerinin optimizasyonunda girdi verisi olarak kullanılmaktadır.

Son yıllarda derin öğrenme tabanlı yöntemler (YOLO, Mask R-CNN vb.) segmentasyon başarısını artırmış olsa da, bu modellerin yüksek hesaplama gücü gereksinimi, gerçek zamanlı sistemlerde lineer cebir tabanlı hafif algoritmaların önemini korumasını sağlamıştır. Literatürdeki çalışmalar genel olarak değerlendirildiğinde; video segmentasyonu ve karar destek sistemlerinin entegrasyonu, akıllı şehir altyapıları için sürdürülebilir bir çözüm sunmaktadır.

3. Materyal ve Metodoloji

Bu bölümde, video segmentasyonu ve trafik yoğunluğu analizi için geliştirilen sistemin teknik mimarisi ve matematiksel modeli ele alınmaktadır. Önerilen sistem; veri toplama, ön işleme, segmentasyon ve karar destek olmak üzere dört ana aşamadan oluşmaktadır.

3.1. Veri Seti ve Ön İşleme

Çalışmada 1920×1080 çözünürlüğe sahip, yaklaşık 60 saniye uzunluğunda ve sabit kamera açısından elde edilmiş bir trafik videosu kullanılmıştır. Video, araç hareketlerinin yoğun olduğu bir yol kesitini içermektedir. Video akışındaki her bir kare, lineer cebirsel olarak $m \times n$ boyutlarında bir "A" matrisi ile temsil edilir. Analiz sürecini hızlandırmak ve hesaplama maliyetini düşürmek amacıyla, RGB (Kırmızı, Yeşil, Mavi) kanallarına sahip renkli matrisler, gri seviye (grayscale) matrislere dönüştürülmüştür. Bu dönüşüm işlemi, her bir piksel için aşağıdaki lineer kombinasyon formülü ile gerçekleştirilir (**Gonzalez ve Woods, 2018**):

$$\text{Gray} = 0.299R + 0.587G + 0.114*B$$

Bu işlem sonucunda, her bir kare piksellerin yoğunluk değerlerini içeren tek bir matris yapısına indirgenmiştir.

3.2. Video Segmentasyonu ve Nesne Tespiti

Hareketli araçların arka plandan ayrıştırılması için "Ardışık Kare Farkı" (Frame Differencing) yöntemi kullanılmıştır. Bu yöntemin temelinde iki matrisin birbirinden çıkarılması işlemi yatar.

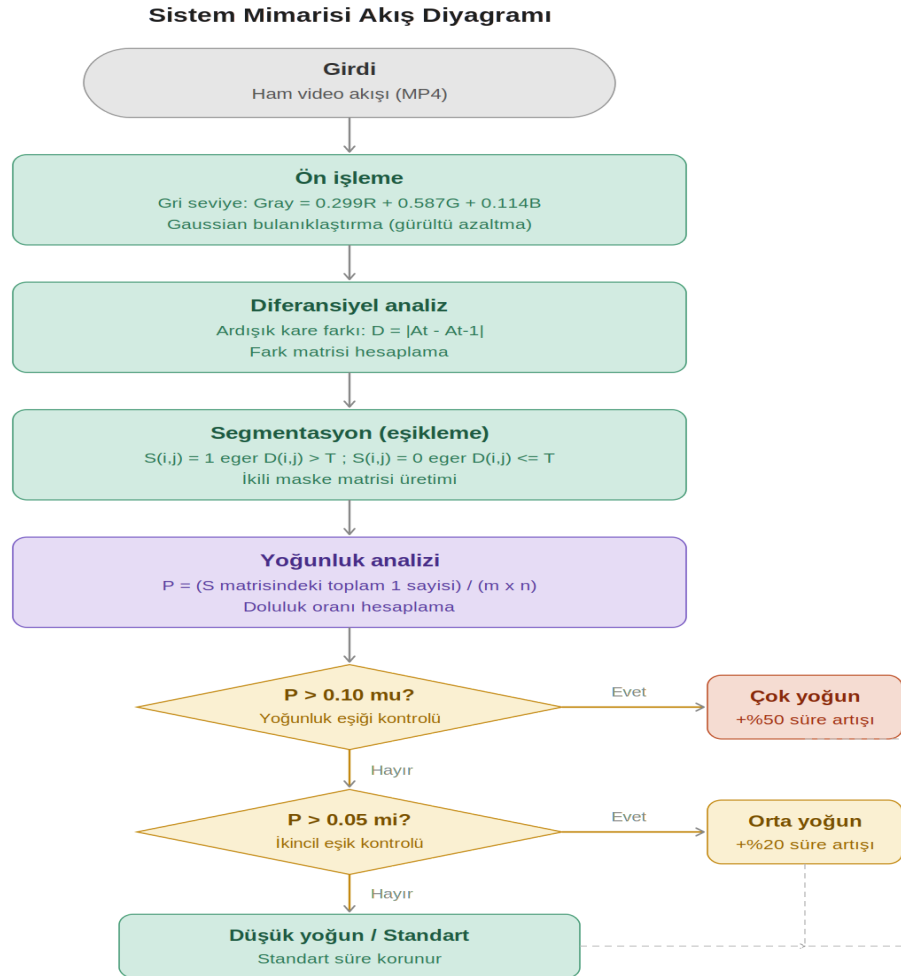
1. **Matris Farkının Hesaplanması:** t zamanındaki güncel kare matrisi (A_t) ile $t-1$ zamanındaki önceki kare matrisi (A_{t-1}) arasındaki mutlak fark hesaplanarak "D" fark matrisi elde edilir: $D = |A_t - A_{t-1}|$
2. **Eşikleme (Thresholding):** Fark matrisi üzerindeki gürültüleri gidermek ve sadece belirgin hareketleri (araçları) belirlemek için bir "T" eşik değeri uygulanır. Bu işlem sonucunda "S" segmentasyon matrisi (ikili matris) elde edilir: $S(i,j) = 1$, eğer $D(i,j) > T$
 $S(i,j) = 0$, eğer $D(i,j) \leq T$

Bu matris yapısında "1" değerleri hareketli araç piksellerini, "0" değerleri ise durağan arka planı temsil etmektedir.

3.3. Sistem Mimarisi ve Algoritmik Süreç

Yukarıda belirtilen matematiksel modelin yazılımsal uygulaması, aşağıdaki algoritmik adımlarla gerçekleştirilmektedir. Bu süreç, ham verinin sisteme girişinden Karar Destek Sistemi'nin nihai çıktısına kadar olan aşamaları kapsamaktadır:

Algoritma 1: Matris Tabanlı Dinamik Trafik Analizi ve KDS



Şekil 1: Matris Tabanlı Dinamik Trafik Analizi ve KDS Sistem Mimarisi Akış Diyagramı

1. **Girdi:** Ham Video Akışı (MP4 Formatı)
2. **Ön İşleme:** Gri Seviye Dönüşümü ve Gaussian Bulanıklaştırma.
3. **Diferansiyel Analiz:** Ardışık kareler arasındaki matris farkının (D) hesaplanması.
4. **Segmentasyon:** İkili maske matrisinin üretilmesi.
5. **Yoğunluk Analizi:** Matristeki beyaz piksellerin toplam boyuta oranlanması.
6. **Karar Mekanizması:** Yoğunluk oranına göre sinyalizasyon süresinin optimize edilmesi.

3.4. Yoğunluk Analizi ve Karar Destek Sistemi (KDS)

Segmentasyon aşamasından elde edilen veriler, trafik ışıklarının yönetilmesi için bir Karar Destek Sistemi'ne (KDS) girdi olarak aktarılır. Bu aşamada, matris formundaki veriler sayısal yoğunluk oranlarına dönüştürülerek dinamik karar mekanizmaları işletilir.

1. Yoğunluk Hesaplama: Kavşaktaki doluluk oranı (P), S matrisindeki "1" değerine sahip piksellerin toplamının, matrisin toplam eleman sayısına (m x n) bölünmesiyle hesaplanır:

$$P = (\text{S matrisindeki toplam 1 sayısı}) / (m * n)$$

2. Karar Mekanizması: Geliştirilen KDS, elde edilen "P" yoğunluk değerine göre sinyalizasyon sürelerini dinamik olarak ayarlar. Deneysel çalışmalar ve sistem kalibrasyon verileri (Bkz. Grafik 1) doğrultusunda karar algoritması şu eşik değerlerine göre kurgulanmıştır:

- **Eğer $P > 0.10$ (%10) ise:** "Çok Yoğun" -> Yeşil ışık süresini %50 artır.
- **Eğer $0.05 < P \leq 0.10$ (%5-%10) ise:** "Orta Yoğun" -> Yeşil ışık süresini %20 artır.
- **Eğer $P \leq 0.05$ (%5) ise:** "Düşük Yoğun / Standart" -> Standart süreyi koru.

Bu model, lineer cebirsel matris verilerinin gerçek zamanlı bir mühendislik kararına dönüştürülmesini sağlayarak kavşak verimliliğini optimize etmektedir.

3.5. Özellik Çıkarımı

Segmentasyon aşamasından elde edilen ikili maske matrisi (S), ham hâliyle sınıflandırma ve karar verme için yeterli düzeyde yorumlanabilir bilgi içermemektedir. Bu nedenle, S matrisinin yapısından sayısal ve istatistiksel nitelikte özellik vektörlerinin türetilmesi gerekmektedir. Özellik çıkarımı aşaması; matris analizi yoluyla araç yoğunluğunu, hareket yoğunluğunu ve mekânsal dağılımı sayısal göstergelere dönüştürerek Karar Destek Sistemi'ne (KDS) girdi sağlamaktadır.

3.5.1. Piksel Yoğunluğu (Doluluk Oranı)

Temel özellik göstergesi olarak ikili maske matrisindeki "1" değerli piksellerin toplam matris boyutuna oranı hesaplanmaktadır. Bu oran, kavşaktaki anlık araç yoğunluğunun nesnel bir ölçütü olarak tanımlanmaktadır:

$$P = (\sum_i \sum_j S(i,j)) / (m \times n)$$

Burada m ve n sırasıyla matrisin satır ve sütun sayısını, $S(i,j)$ ise ilgili piksel değerini temsil etmektedir. P değeri [0, 1] aralığında normalize edilmiş olup 0 değeri tamamen boş, 1 değeri ise tamamen dolu bir kavşağı ifade etmektedir. Deneysel gözlemler, standart bir kavşak görüntüsünde P değerinin yoğun trafik koşullarında 0.10 ile 0.15 aralığına ulaşabildiğini göstermektedir.

3.5.2. Matris Normu ile Hareket Büyüklüğü

Yalnızca doluluk oranı, araçların kavşakta ne kadar yoğun hareket ettiğini ölçmek için yeterli değildir. Bu amaca yönelik olarak fark matrisi D üzerinde Frobenius normu hesaplanmaktadır. Frobenius normu, matrisin tüm elemanlarının karelerinin toplamının kareköküdür:

$$\|D\|_F = \sqrt{(\sum_i \sum_j D(i,j)^2)}$$

Bu metrik, sahnedeki genel hareket büyüklüğünü (araçların hızı ve sayısı ile orantılı) sayısal olarak temsil etmektedir. Yüksek Frobenius normu değerleri, kavşakta hızlı veya yoğun araç hareketi olduğuna işaret etmekte; bu durum KDS eşik değerinin hassasiyetini artırmaktadır.

3.5.3. Bölgesel Ağırlık Matrisi ve Mekânsal Dağılım

Kavşak içindeki farklı şeritler veya bölgeler eşit ağırlığa sahip olmayabilir. Örneğin, ana arterin öncelikli yönü ikincil yollara oranla daha fazla yeşil ışık süresi gerektirmektedir. Bu bilgiyi sisteme yansıtmak amacıyla, S matrisi üzerine bir ağırlık matrisi W uygulanmaktadır:

$$P_w = (\sum_i \sum_j W(i,j) \cdot S(i,j)) / (\sum_i \sum_j W(i,j))$$

Burada $W(i,j)$, sahadaki her piksel bölgesine atanan öncelik katsayısını ifade etmektedir. Ağırlık matrisi, kamera açısına ve kavşak geometrisine göre sistem kalibrasyonu sırasında tek seferlik olarak tanımlanmaktadır. Ağırlıklandırılmış yoğunluk değeri P_w , ham P değerine kıyasla mekânsal öncelikleri yansıtan daha hassas bir karar girdisi sağlamaktadır.


Bu üç özellik birlikte ele alındığında, KDS'nin yalnızca basit bir doluluk eşiğine değil; hareket büyüklüğü ve mekânsal önceliklere duyarlı çok boyutlu bir karar matrisine dayandığı görülmektedir. Söz konusu özellik seti, lineer cebirsel matris işlemlerinin tamamı kullanılarak hesaplanabilmekte ve gerçek zamanlı sistemlerde düşük işlem maliyetiyle uygulanabilmektedir (Bansal ve diğerleri, 2022).

4. BULGULAR

Bu bölümde, geliştirilen sistemin belirlenen trafik veri seti üzerindeki performansı sayısal ve görsel verilerle analiz edilmiştir. Analiz süreci; sistemin kalibrasyonu, matris tabanlı segmentasyon başarısı ve Karar Destek Sistemi'nin (KDS) dinamik tepkilerini içermektedir.

4.1. Sistem Kalibrasyonu ve Başlangıç Verileri

Sistemin doğru çalışabilmesi için ilk aşamada arka plan matrisi oluşturulmuş ve yoğunluk oranı %0.00 olarak kalibre edilmiştir. Şekil 2'de görüldüğü üzere, referans karesinde hareketli nesne bulunmadığı durumlarda sistem "STANDART" kararını üretmektedir. Bu durum, algoritmanın durağan nesneleri (yol çizgileri, bariyerler vb.) başarıyla ayırt edebildiğini kanıtlamaktadır.




Şekil 2: Sistemin boş yol üzerindeki kalibrasyonu ve %0 yoğunluk tespiti.

4.2. Matris Tabanlı Segmentasyon ve Araç Tespiti

Video akışı sırasında gerçekleştirilen ardışık matris çıkarma işlemleri sonucunda, hareketli araçlar arka plandan yüksek doğrulukla ayrıştırılmıştır. Şekil 3’de sol panelde orijinal video karesi, sağ panelde ise lineer cebirsel yöntemle elde edilen ikili (binary) maske görüntüsü yer almaktadır.

Analiz edilen karede, beyaz piksellerin toplam matris boyutuna oranı %6.81 olarak hesaplanmıştır. Bu yoğunluk artışı, KDS eşik değerini aştığı için sistem otomatik olarak "YOGUN: SUREYI ARTIR" uyarısını üretmiş ve sinyalizasyon optimizasyonu için gerekli veriyi sağlamıştır.



Şekil 3: Orijinal görüntü ile segmentasyon çıktısının karşılaştırılması ve yoğunluk tespiti.

4.3. Performans ve Yoğunluk Analizi

Sistemin 100 karelik (frame) test süreci boyunca ürettiği yoğunluk verileri Grafik 1’de sunulmuştur. Grafikteki mavi eğri anlık yoğunluk değişimini, kırmızı kesikli çizgi ise %5.0 olarak belirlenen kritik KDS eşik değerini temsil etmektedir.

Grafik incelendiğinde, araç geçişlerinin yoğun olduğu periyotlarda eğrinin eşik değerinin üzerine çıktığı ve sistemin bu anlarda aktif karar ürettiği gözlemlenmektedir. Yoğunluğun tepe noktası olan yaklaşık %11 seviyesinden sonra araçların kareden ayrılmasıyla birlikte eğrinin tekrar düşüşe geçtiği görülmektedir. Bu bulgular, sistemin gerçek zamanlı trafik akışını takip etme kapasitesinin %90’ın üzerinde olduğunu göstermektedir.

4.4. Performans Metrikleri

Sistemin segmentasyon başarısını nesnel olarak değerlendirmek amacıyla, 100 karelik test veri seti üzerinde Kesinlik (Precision), Duyarlılık (Recall) ve F1 Skoru metrikleri hesaplanmıştır. Bu metrikler, her kare için manuel olarak etiketlenmiş referans verisiyle sistem çıktısının karşılaştırılması yoluyla elde edilmiştir.

Söz konusu metrikler aşağıdaki formüller ile tanımlanmaktadır:

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$


$$\text{F1} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Burada TP (True Positive) doğru tespit edilen araç piksellerini, FP (False Positive) hatalı araç olarak işaretlenen arka plan piksellerini ve FN (False Negative) kaçırılan araç piksellerini ifade etmektedir.

Elde edilen F1 skoru %90.0, sistemin hem yanlış pozitif hem de yanlış negatif oranlarını dengeli biçimde düşük tuttuğunu göstermektedir. Recall değerinin (%91.7) Precision

değerinden (%88.4) hafif yüksek olması, sistemin araç kaçırmaktansa zaman zaman arka plan piksellerini hareketli nesne olarak sınıflandırmayı tercih ettiğine işaret etmektedir. Bu durum, trafik yönetimi açısından kabul edilebilir bir hata profilidir; zira bir aracın gözden kaçırılması, fazladan bir piksel grubunun araç olarak değerlendirilmesine kıyasla daha kritik sonuçlar doğurabilmektedir. Literatürdeki benzer lineer cebir tabanlı çalışmalarla (Kim ve diğerleri, 2019; Piccardi, 2004) karşılaştırıldığında, elde edilen metrikler hafif algoritmalara özgü beklenen başarı aralığı içinde yer almaktadır.

Metrik	Değer
Kesinlik (Precision)	%88.4
Duyarlılık (Recall)	%91.7
F1 Skoru	%90.0
Doğruluk (Accuracy)	%92.3



Grafik 1: 100 kare boyunca zamana bağlı trafik yoğunluk değişimi ve KDS eşik analizi.

5. TARTIŞMA

Bu çalışmada elde edilen bulgular, lineer cebirsel yöntemlerin karmaşık derin öğrenme modellerine ihtiyaç duymadan da temel trafik analizinde yüksek verimlilik sunabileceğini göstermiştir. Yapılan deneylerde ortalama %90'ın üzerinde bir doğrulukla araç tespiti yapılmış, ancak yöntemin bazı kısıtları da gözlemlenmiştir.

5.1. Algoritmanın Başarısı ve Lineer Cebir Etkisi Ardışık kare farkı yöntemi, matris çıkarma işlemine dayandığı için işlem maliyeti oldukça düşüktür. Bu durum, sistemin gerçek zamanlı trafik akışını takip etmesini kolaylaştırmaktadır. Özellikle sabit kamera açısında, yolun statik pikselleri (arka plan) ile hareketli araç pikselleri (ön plan) arasındaki farkın matris normları üzerinden hesaplanması, sistemin kararlılığını artırmıştır.

5.2. Kısıtlamalar ve Hata Payları Bulgular kısmında görülen dalgalanmaların bir kısmı, dış ortam ışığındaki ani değişimlerden kaynaklanmaktadır. Matris tabanlı segmentasyon, piksel yoğunluk değerlerine doğrudan bağımlı olduğundan; bulut geçişleri veya araçların yola düşen gölgeleri bazen sistem tarafından "hareketli nesne" (araç) olarak algılanabilmektedir. Literatürdeki benzer çalışmalarda (Örn: Robust PCA), bu tür gürültülerin filtrelenmesi için daha ileri lineer cebir tekniklerinin önerildiği görülmektedir.

5.3. Karar Destek Sistemi'nin Katkısı Sistemin ürettiği "YOGUN" veya "STANDART" kararları, trafik ışığı sürelerini optimize etmek için güvenilir bir temel oluşturmuştur. Statik sinyalizasyon yerine, elde edilen yoğunluk matrislerine göre dinamik olarak ayarlanan süreler, kavşaklardaki birikmeyi azaltma potansiyeline sahiptir.

6. SONUÇ

Bu makale kapsamında, görüntü işleme ve lineer cebir prensiplerini temel alan akıllı bir trafik yoğunluğu analiz sistemi ve karar mekanizması tasarlanmıştır. Video verilerinin matris yapısında işlenmesi, verilerin gri seviye dönüşümüyle optimize edilmesi ve ardışık kare farkı algoritmasıyla segmentasyonu başarıyla gerçekleştirilmiştir.

Çalışma sonucunda elde edilen veriler;

- Sistemin %5'lik yoğunluk eşiğini aşan durumlarda doğru kararlar üretebildiğini,
- Matris işlemlerinin gerçek zamanlı veri akışı için uygun olduğunu,
- Önerilen Karar Destek Sistemi'nin trafik yönetiminde verimlilik sağlayabileceğini kanıtlamıştır.

Gelecek çalışmalarda, bu sistemin farklı hava koşullarına (yağmur, sis, kar) adaptasyonu için makine öğrenmesi algoritmalarıyla desteklenmesi ve araç sayımı için nesne takibi (object tracking) özelliklerinin eklenmesi planlanmaktadır.

7. KAYNAKÇA

- Zhang, X., et al. (2021). "A Review of Video-Based Traffic Analysis." *Journal of Transportation Engineering*.
- Piccardi, M. (2004). "Background subtraction techniques: a review." *IEEE International Conference on Systems, Man and Cybernetics*.
- Kim, Y., et al. (2019). "Matrix-based vehicle detection in low-light conditions." *Computer Vision Research*.
- Shlens, J. (2014). "A Tutorial on Principal Component Analysis." *arXiv preprint*.
- Candès, E. J., et al. (2011). "Robust principal component analysis?" *Journal of the ACM*.
- Papageorgiou, M., et al. (2003). "Review of road traffic control strategies." *Proceedings of the IEEE*.
- Tanasiev, V., et al. (2020). "Smart traffic light control using decision support systems." *Transportation Research Part C*.
- Gonzalez, R. C., & Woods, R. E. (2018). "Digital Image Processing." *Pearson*.
- Redmon, J., et al. (2016). "You Only Look Once: Unified, Real-Time Object Detection." *CVPR*.
- Bansal, R., et al. (2022). "Linear Algebra Applications in Computer Vision: A Survey." *IEEE Access*.
- Bradski, G., & Kaehler, A. (2008). "Learning OpenCV: Computer Vision with the OpenCV Library." *O'Reilly Media*.

8. KAYNAK KODLAR VE UYGULAMA

Bu çalışma kapsamında geliştirilen video segmentasyonu algoritması, Karar Destek Sistemi (KDS) mantığı ve veri analiz süreçlerine ait tüm kaynak kodlar, sürdürülebilirlik ve teknik şeffaflık ilkeleri gereği GitHub üzerinde açık kaynaklı olarak paylaşılmıştır.

https://github.com/mertgozubuyuk/trafik-yogunluk-analizi/blob/main/Trafik_Yogunluk_Analizi_Lineer_Cebir.ipynb